




กระบวนการเตรียมข้อมูล Scopus สำหรับ Machine Learning

EDA • Data Cleaning • Visualization • Text Embedding • Feature Vector

จากบทความวิจัย 6,000 รายการ → ชุดข้อมูลพร้อมส่งต่อให้โมเดล ML

รายชื่อสมาชิกกลุ่ม:

66011211002 นาย กฤษณะ เทพฤทธิ์

66011211049 นาย ยุติธรรม ปั่นกลาง


66011211174 นางสาว นัฐกานต์ ทองเชื้อ

66011211097 นาย อติศร บุญเหมาะ

66011211162 นางสาว นัฐกานต์ ตาทอง

กระบวนการทำ EDA (Exploratory Data Analysis) และ (Data Cleaning)

เปลี่ยน bibliographic data ให้เป็นข้อมูลสะอาด วิเคราะห์ได้ และแปลงเป็นเวกเตอร์เชิงความหมาย



การรวมและคัดเลือกข้อมูล

ข้อมูลเริ่มต้นมาจาก Scopus โดย export เป็น CSV ก่อนนำมารวมใน Python / Google Colab

10

ไฟล์ CSV ที่รวบรวม

6,000

รายการข้อมูลดิบ

600

รายการต่อ Subject ตามโครงร่าง

แหล่งข้อมูล

SCOPUS

โครงสร้างข้อมูลที่ใช้

Title

ชื่อเรื่อง

Abstract

บทคัดย่อ

Author Keywords

คำสำคัญผู้แต่ง

Index Keywords

คำสำคัญฐานข้อมูล

Collection → Concatenate

ใช้ glob ค้นหา CSV ทั้ง 10 ไฟล์ แล้วต่อกันด้วย pandas ทำให้ได้ข้อมูลดิบเริ่มต้นจำนวน 6,000 รายการ

Python + Google Colab

เป้าหมายคือได้ตารางเดียวที่พร้อมเข้าสู่ขั้นตอน cleaning

จุดเปลี่ยนสำคัญ: 6,000 → 5,459 รายการสุทธ

ลบความซ้ำ จัดการข้อความขยะ และทำให้โครงสร้างข้อมูลพร้อมประมวลผลต่อ

1. Remove duplicates

ทำการกรองเปเปอร์ที่ชื่อเรื่อง (title) ซ้ำกันออก โดยกำหนดพารามิเตอร์ keep=False เพื่อลบข้อมูลที่มีความซ้ำซ้อนทั้งหมด หลังจากการลบข้อมูลซ้ำซ้อน ทำให้เหลือข้อมูลสุทธที่พร้อมใช้งานจำนวน 5,459 รายการ

6,000 → 5,459

รายการพร้อมใช้งาน

-541 duplicates / redundant rows

2. Text cleaning

ทำการค้นหาและลบประโยคลิขสิทธิ์ที่เป็นแพทเทิร์นซ้ำซาก (เช่น "Copyright (c) 2026 The Authors. This work is licensed under a Creative Commons") ออกจากคอลัมน์ abstract เพื่อให้ข้อมูลสะอาดและไม่รบกวนการเรียนรู้ของโมเดล Machine Learning

3. Missing values

ตรวจสอบและแทนที่ค่าว่าง (Null) ทั้งหมดด้วยช่องว่าง (Empty string) โดยใช้คำสั่ง fillna("") เพื่อป้องกันไม่ให้เกิด Error ในขั้นตอนการรวมประโยค จากการใช้คำสั่ง info() พบว่าทุกคอลัมน์ (5,459 แถว) ไม่มีค่าว่างหลงเหลืออยู่ (Non-Null Count ครบถ้วน)

ผลลัพธ์เชิงข้อมูล

Dataset สะอาดขึ้น → พร้อมทำ EDA, Visualization และ Text Embedding

ก่อนฝึกโมเดล: รู้จัก “ข้อความ” ที่จะป้อนให้โมเดล

EDA ช่วยตรวจสอบโครงสร้างข้อมูล ขณะเดียวกันการรวมข้อความจะรักษารูปแบบของแต่ละบทความ

EDA CHECKPOINTS

- 1 **Rows / Columns**
ตรวจสอบจำนวนแถวและคอลัมน์
- 2 **Keyword Frequency**
ดูคำที่ปรากฏบ่อยจากคอลัมน์ author_keywords
- 3 **Abstract Length**
สำรวจปริมาณข้อความ
- 4 **Feature Fields**
เลือก 4 ช่องสำคัญ

4 fields → 1 embedding_text

Text Concatenation

ใส่ Prefix เพื่อให้โมเดลรู้ว่าแต่ละส่วนคือบริบทชนิดใด

Title:	[ชื่อเรื่อง]
Abstract:	[บทคัดย่อ]
Author keywords:	[คำสำคัญ]
Index keywords:	[คำสำคัญดัชนี]

รักษารูปแบบก่อนแปลงเป็นเวกเตอร์


ผลลัพธ์: dataset สะอาด 5,459 รายการ พร้อมนำไปสร้าง Visualization และเตรียมข้อความสำหรับ Embedding ต่อ

สัดส่วนนิยม


กราฟ Treemap แสดงสัดส่วนความนิยมของคำสำคัญทั้งหมดในชุดข้อมูล ขนาดและความเข้มของกล่องแปรผันตามความถี่ที่คำนั้นปรากฏในเปอร์

Keyword Treemap

แสดงให้เห็นความสัมพันธ์เชิงเวลา (Time-Series) อย่างชัดเจนว่า งานวิจัยแทบทุกหมวดหมู่มีปริมาณการตีพิมพ์พุ่งสูงขึ้นอย่างก้าวกระโดด (Spike) ในช่วงปี 2025 - 2026 โดยเฉพาะเทรนด์ของ Large Language Models และ Generative AI ที่ขยายตัวกว้างขึ้นอย่างเห็นได้ชัดในปลายน้ำ



เทรนด์เร่งตัวอย่างชัดเจนในปี 2025-2026





Keyword Theme River

กราฟกระแสน้ำแสดงวิวัฒนาการของคำสำคัญยอดฮิต 10 อันดับแรกตามช่วงเวลา (ปีที่ตีพิมพ์) ความหนาของแถบสีแสดงถึงปริมาณงานวิจัยในแต่ละปี แสดงความสัมพันธ์เชิงเวลา (Time-Series) อย่างชัดเจนว่า งานวิจัยมีปริมาณการตีพิมพ์พุ่งสูงขึ้นอย่างก้าวกระโดด (Spike) ในช่วงปี 2025 - 2026 โดยเฉพาะเทรนด์ของ Large Language Models และ Generative AI ที่ขยายตัวกว้างขึ้นอย่างเห็นได้ชัดในข้อมูลช่วงหลัง

กราฟงานวิจัยพุ่งสูงขึ้นก้าวกระโดดในปี 2025-2026 โดยเฉพาะ LLM และ Generative AI

Keyword Trend Heatmap และ Emerging Keyword Quadrant

Heatmap ยืนยันความหนาแน่นของ Deep Learning / Machine Learning ขณะที่ Quadrant ช่วยมองดาวรุ่งตาม Growth rate



HIGH DENSITY • 2026 Deep Learning + Machine Learning


แผนภาพความร้อนที่แสดงระดับความหนาแน่นของ Keyword ในแต่ละปี สันนิษฐานว่ามีความหมายถึงมีเปเปอร์ที่ใช้คำนั้นจำนวนมาก

EMERGING Federated Learning • Generative AI • Edge Computing

กราฟ Scatter Plot แบบแบ่งจตุภาค (Quadrant) แกน X แสดงอัตราการเติบโต (Growth rate) และแกน Y แสดงความถี่ปัจจุบัน (Frequency)

Keyword Co-occurrence Network

เครือข่ายใยแมงมุมแสดงความสัมพันธ์ของคำสำคัญ โหนดขนาดใหญ่คือคำที่เจอบ่อย โทนสีแดง/โทนอุ่น หมายถึงเปเปอร์ในปีล่าสุด
เส้นเชื่อม (Edge) คือการถูกนำมาทำวิจัยร่วมกัน



3 signals from the network

- NODE SIZE

คำที่พบ/ถูกเชื่อมโยงบ่อย
- EDGE

งานวิจัยที่ใช้ keyword ร่วมกัน
- WARM TONE


งานวิจัยช่วงล่าสุด

Interpretation

แสดงให้เห็นโครงสร้างการบูรณาการเทคโนโลยี โหนดขนาดใหญ่ที่เป็นสีแดงเข้มตรงกลางบ่งบอกว่างานวิจัยยุคใหม่ๆ มีการนำเทคโนโลยีหลายแขนงมาผสมผสานกันเป็นเครือข่ายแน่นหนา มากกว่าการทำวิจัยแบบแยกส่วนเหมือนในอดีต

SPECTER2 (allenai/specter2_base) ทำงานร่วมกับ Adapter ผ่านไลบรารี Transformers

ใช้ embedding model ที่ออกแบบมาสำหรับบทความวิชาการ เพื่อแปลงข้อความเป็นตัวเลขที่วัดความคล้ายคลึงได้



เหตุผลที่ใช้ SPECTER2

เป็นโมเดล AI ขั้นสูงที่ถูกฝึกสอน (Pre-trained) มาให้อ่านและทำความเข้าใจ "บทความวิจัยทางวิทยาศาสตร์และวิชาการ" โดยเฉพาะ ทำให้สามารถจับใจความสำคัญของเปเปอร์สายเทคโนโลยีได้ดีกว่าโมเดลภาษาทั่วไป

L2 Normalization

ปรับเวกเตอร์ให้มีสเกลมาตรฐานเดียวกัน เพื่อให้วัดระยะห่าง / similarity ขึ้นตอนนี้สำคัญมากเพราะจะช่วยให้อัลกอริทึม Machine Learning วัดระยะห่างหรือความคล้ายคลึงของเปเปอร์แต่ละฉบับได้อย่างแม่นยำ

Input = context-rich text

Output = numeric vector

Ready for ML algorithms

ผลลัพธ์สุดท้ายที่ได้คือ ชุดข้อมูล Feature Vector

ทุกบทความถูกแปลงเป็นเวกเตอร์ขนาด **768D** และส่งต่อให้ขั้นตอน Machine Learning ได้ทันที

(5,459 , 768)

ROWS

DIMENSIONS

paper 5,459 ฉบับ

ถูกเข้ารหัสเป็น 768 features ต่อฉบับ

พร้อมใช้เป็น Train Data

K-Means

จัดกลุ่ม paper ที่คล้ายกัน

KNN

ค้นหา paper ที่ใกล้เคียงที่สุด

Classification*

ทำนายงานจำแนกประเภท

TAKEAWAY

Clean data → Understand trends → Preserve context → Embed → Ready for ML